Regresión

Dra. Consuelo Varinia García Mendoza

Regresión y correlación

- En la práctica a menudo se requiere resolver problemas que implican conjuntos de variables que están correlacionadas.
  - El rendimiento del combustible de un motor está relacionado con su volumen
  - ¿Qué variables están relacionadas con el precio de una casa?
- Es de interés un método de pronóstico
  - El rendimiento de cualquier motor dado su volumen
  - El precio de cualquier casa dado tu tamaño

Aprendizaje supervisado

- En el aprendizaje supervisado se tiene un conjunto de datos *x* y a partir de ellos se intenta predecir un conjunto de valores *y*
- El objetivo es crear un modelo que aprenda de los datos *x* y los relacione con los valores de *y*
- Esta relación (mapping) entre los datos de x y los valores y se puede determinar mediante una función *h(x)*
- Los valores a predecir pueden ser continuos o discretos

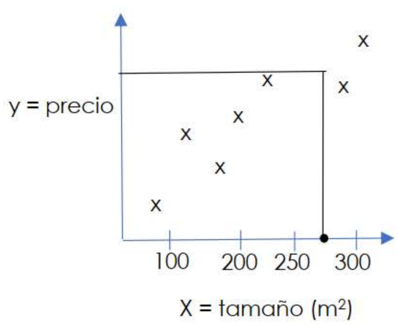

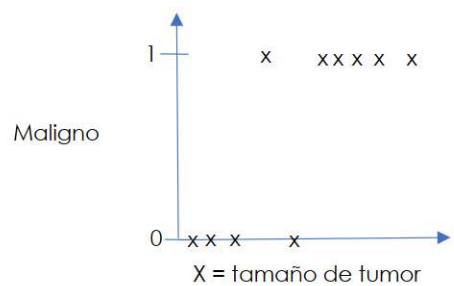

Relación no determinista

Ejemplos:

- Autos con motores del mismo volumen pueden tener distinto rendimiento de combustible
- Casas con la misma superficie de construcción distintos precios

Componente aleatorio relacionado no otras variables independientes o incluso elementos desconocidos.

- A pesar de que no se pude hacer un pronóstico exacto si es posible hacer un pronóstico estimado o ajustado

Regresión

- Regresión lineal
- Regresión no lineal

H $\rightarrow$ y

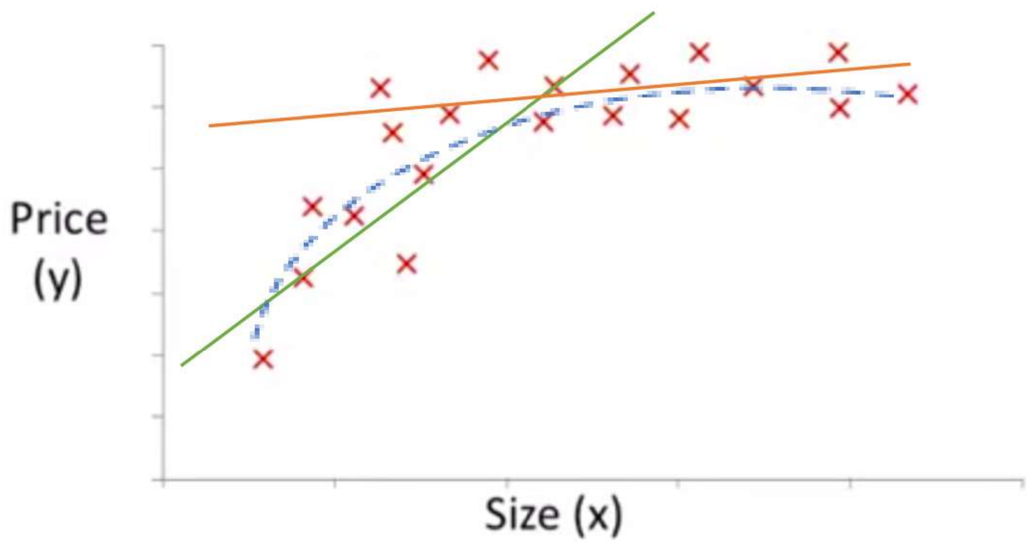

Pronóstico estimado o ajustado $\hat{y}$

Relación lineal

$$\hat{y} = b_0 + b_1 x$$

donde

b_0 : intersección

b_1 : pendiente

x : variable independiente o regresor (tamaño de la casa, volumen del motor)

$\hat{y}$: variable dependiente o respuesta estimada (precio, rendimiento del combustible)

Error de estimación

Cada recta de regresión que elijamos para modelar los datos tendrá asociada una suma del error respecto a la recta de regresión estimada

$$\sum_{I=1}^{n} |y_i - \widehat{y_i}|$$

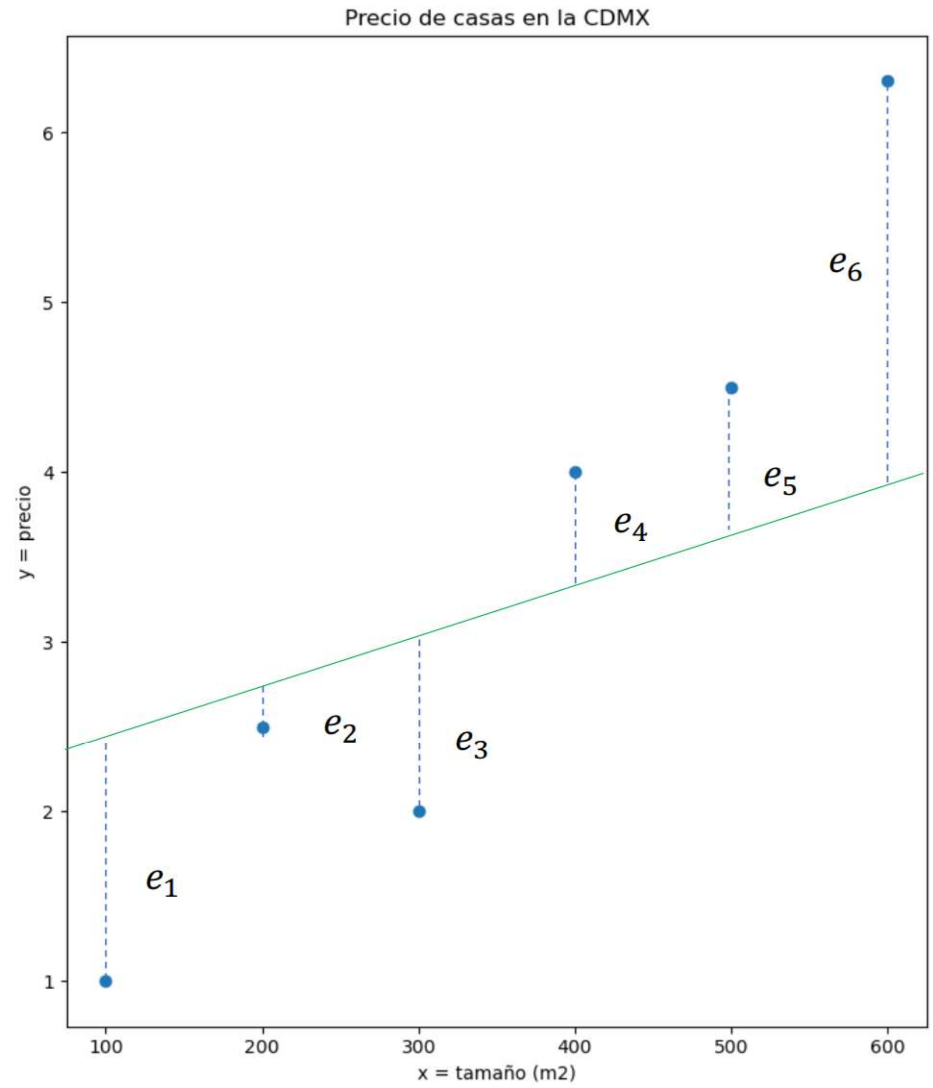

Función de perdida

Suma de los cuadrados del error respecto a la recta de regresión estimada

$$\mathrm{SCE}\left(b_{0,}\, b_1\right) = \sum_{I=1}^{n} {e_i}^2 = \sum_{I=1}^{n} (y_i - \widehat{y_i})^2$$

- **Problema de optimización**

$$\frac{\partial \mathrm{SCE}\left(b_{0,}\, b_1\right)}{\partial b_0} = 0$$

$$\frac{\partial \mathrm{SCE}\left(b_{0,}\, b_1\right)}{\partial b_1} = 0$$

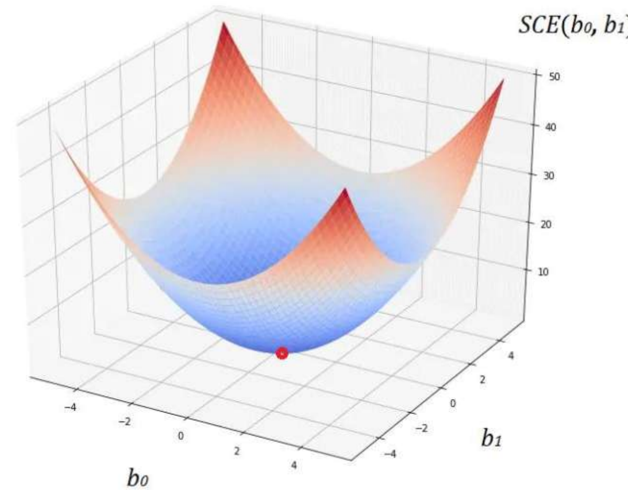

Mínimos cuadrados ordinarios (OLS)

- Método analítico

$$\frac{\partial \mathrm{SCE}\left(b_{0,}\, b_1\right)}{\partial b_0} = \frac{\partial \sum_{l=1}^{n} (y_i - b_0 - b_1 x_i)^2}{\partial b_0} = 0$$

$$\frac{\partial \mathrm{SCE}\left(b_{0,}\, b_1\right)}{\partial b_1} = \frac{\partial \sum_{l=1}^{n} (y_i - b_0 - b_1 x_i)^2}{\partial b_1} = 0$$

- $b_0 = \dfrac{\sum_{i=1}^{n} y_i - b_1 \sum_{i=1}^{n} x_i}{n}$

- $b_1 = \dfrac{n \sum_{i=1}^{n} x_i y_i - \left(\sum_{i=1}^{n} x_i\right)\left(\sum_{i=1}^{n} y_i\right)}{n \sum_{i=1}^{n} {x_i}^2 - \left(\sum_{i=1}^{n} x_i\right)^2}$

Mínimos cuadrados ordinarios (OLS)

$$b_0 = \frac{\sum_{i=1}^{n} y_i - b_1 \sum_{i=1}^{n} x_i}{n}$$

$$b_1 = \frac{n \sum_{i=1}^{n} x_i y_i - \left(\sum_{i=1}^{n} x_i\right)\left(\sum_{i=1}^{n} y_i\right)}{n \sum_{i=1}^{n} {x_i}^2 - \left(\sum_{i=1}^{n} x_i\right)^2}$$

$$\hat{y} = b_0 + b_1 x$$

Desventajas de OLS

Con este método no hay aprendizaje, no se aprende del error

Tiene dificultades cuando las variables independientes presentan multicolinealidad entre ellas, esto es que están correlacionadas

Las variables independientes (características) deben tener correlación con la salida (target) pero no entre ellas.

Desventajas de OLS

Otra desventaja de este método es que su costo computacional el cuál aumenta considerablemente al aplicarlo a conjuntos de datos grandes con muchas instancias y variables (características)

- $\hat{y} = b_0 + b_1 x$

$$\frac{\partial \mathrm{SCE}(b_{0,} b_1)}{\partial b_0} = \frac{\partial \sum_{I=1}^{n} (y_i - b_0 - b_1 x)^2}{\partial b_0} = 0$$

$$\frac{\partial \mathrm{SCE}(b_{0,} b_1)}{\partial b_1} = \frac{\partial \sum_{I=1}^{n} (y_i - b_0 - b_1 x)^2}{\partial b_1} = 0$$

$$\hat{y} = b_0 + b_1 x_1 + \cdots + b_n x_n$$

- Requiere calcular $n + 1$ derivadas
- Resolver un sistema de $n + 1$ ecuaciones
- Hacer sumarias de m muestras, ejemplos o instancias